

EDA en R: Estadísticas de los estudiantes de Educación Superior inscritos en el Instituto
Tecnológico de las Américas (ITLA) 2006 - 2025

Por:

Julián Alejandro Núñez Toribio

Asignación presentada a la

Escuela de Informática, Facultad de Ciencias, Como cumplimiento del Curso

“Visualización de Datos II”

Mtro. Jorge Ramón Taveras González

Universidad Autónoma de Santo Domingo (UASD)

2026

Análisis Exploratorio de Datos (EDA) en R

Estadísticas de los estudiantes de Educación Superior inscritos en el Instituto Tecnológico de las Américas (ITLA) 2006 – 2025

El Instituto Tecnológico de Las Américas (ITLA) es una institución técnica de estudios superiores, fundada en el año 2000 por el Estado dominicano. Única especializada en educación tecnológica en la República Dominicana.

Este conjunto de datos contiene las estadísticas de los estudiantes de Educación Superior inscritos en el Instituto Tecnológico de las Américas (ITLA) 2006 - 2025, en el cual se puede encontrar los estudiantes inscritos por cuatrimestre en las distintas carreras.

Este análisis exploratorio de datos (EDA) tiene como objetivo comprender el comportamiento de la matrícula en carreras del área tecnológica, analizando su distribución, evolución en el tiempo y diferencias por sexo. A continuación, detallamos los pasos realizados en R para el Análisis Exploratorio de Datos (EDA).

1- Carga del Dataset

```
df_carreras <- read.csv("Estadisticas-Inscritos-Educacion-Superior-2006-2025.csv")
```

Visualizar primeras filas

```
head(df_carreras)
```

	Carrera	Estudiantes.femeninos	Estudiantes
.masculinos			
1	Tecnólogo en Desarrollo de Software	3	
6	Septiembre- Diciembre 2006		
2	Tecnólogo en Multimedia	8	
9	Septiembre- Diciembre 2006		
3	Tecnólogo en Redes de Información	13	
19	Septiembre- Diciembre 2006		
4	Tecnólogo en Manufactura Automatizada	8	
5	Septiembre- Diciembre 2006		
5	Tecnólogo en Desarrollo de Software	8	
13	Enero - Abril 2007		
6	Tecnólogo en Manufactura Automatizada	13	
12	Enero - Abril 2007		

>

2- Exploración del Dataset

Nombres de columnas

```
colnames(df_carreras)

[1] "Carrera"                "Estudiantes.femeninos" "Estudiantes.masculinos" "Cuatrimestre"
[5] "Año"
```

Estructura de los datos

```
str(df_carreras)

'data.frame':  475 obs. of  5 variables:
 $ Carrera      : chr  "Tecnólogo en Desarrollo de Software" "Tecnólogo en Multimedia" "Tecnólogo en Redes de Información" "Tecnólogo en Manufactura Automatizada" ...
 $ Estudiantes.femeninos : int  3 8 13 8 8 13 14 17 9 14 ...
 $ Estudiantes.masculinos: int  6 9 19 5 13 12 15 28 14 13 ...
 $ Cuatrimestre   : chr  "Septiembre- Diciembre" "Septiembre- Diciembre" "Septiembre- Diciembre" "Septiembre- Diciembre" ...
 $ Año           : int  2006 2006 2006 2006 2007 2007 2007 2007 2007 2007 ...
```

Resumen estadístico

```
summary(df_carreras)
```

	Carrera	Estudiantes.femeninos	Estudiantes.masculinos	Cuatrimestre
Length	:475	Min. : 0.00	Min. : 2	Length :475
Min.	:2006			
N.unique	: 20	1st Qu.: 10.00	1st Qu.: 42	N.unique : 4
1st Qu.	:2014			
N.blank	: 0	Median : 30.00	Median : 117	N.blank : 0
Median	:2020			
Min.nchar	: 19	Mean : 63.05	Mean : 227	Min.nchar: 13
Mean	:2018			
Max.nchar	: 66	3rd Qu.: 72.00	3rd Qu.: 240	Max.nchar: 21
3rd Qu.	:2023			
Max.		:712.00	Max. :2038	
Max.	:2025			

Se observa la presencia de valores variados en las variables numéricas,

lo que sugiere la existencia de carreras con diferentes niveles de matrícula.

3- Limpieza del Dataset

Se renombran las columnas para facilitar el manejo de los datos

```
colnames(df_carreras) <- c("Carrera", "Femenino", "Masculino", "Cuatrimestre", "Año")
```

Se crea una nueva variable con el total de estudiantes

```
df_carreras$Total <- df_carreras$Femenino + df_carreras$Masculino
```

```
head(df_carreras)
```


	Carrera	Femenino	Masculino	Cuatrimestre
1	Tecnólogo en Desarrollo de Software	3	6	Septiembre- Diciembre 2006
2	Tecnólogo en Multimedia	8	9	Septiembre- Diciembre 2006
3	Tecnólogo en Redes de Información	13	19	Septiembre- Diciembre 2006
4	Tecnólogo en Manufactura Automatizada	8	5	Septiembre- Diciembre 2006
5	Tecnólogo en Desarrollo de Software - Abril 2007	8	13	Enero 2007
6	Tecnólogo en Manufactura Automatizada - Abril 2007	13	12	Enero 2007

4- Análisis Exploratorio de Datos (EDA)

4.1 Análisis de relación entre variables

Visualización general de las variables

```
pairs(df_carreras[, c("Femenino", "Masculino", "Total")])
```




Se analiza de forma más específica la relación entre las variables numéricas del dataset

```
plot(df_carreras$Femenino, df_carreras$Total,
     col = "pink",
     pch = 16,
     main = "Relación entre estudiantes y total",
     xlab = "Cantidad por sexo",
     ylab = "Total de estudiantes")
```

```
points(df_carreras$Masculino, df_carreras$Total,
       col = "blue",
       pch = 16)
```

```
legend("topleft",
      legend = c("Femenino", "Masculino"),
      col = c("pink", "blue"),
      pch = 16)
```




Se observa una relación directa entre la cantidad de estudiantes femeninos y masculinos
con el total de estudiantes, evidenciando que a medida que aumenta cualquiera de estas variables,
el total también incrementa. Esto confirma la dependencia entre las variables analizadas.

4.2 Histograma: Distribución total de estudiantes

Se analiza la distribución de la cantidad total de estudiantes

```
hist(df_carreras$Total,
     main = "Distribución de estudiantes por carrera",
     xlab = "Cantidad de estudiantes",
     col = "steelblue")
```



*# La mayoría de las carreras presentan una cantidad baja de estudiantes,
mientras que pocas concentran valores más altos, lo que indica una distribución desigual.*

4.3 Distribución por sexo

Totales por sexo

```
totales_sexo <- colSums(df_carreras[, c("Femenino", "Masculino")])
```

Convertir a porcentaje

```
porcentaje <- round(totales_sexo / sum(totales_sexo) * 100, 1)
```


Gráfico de barras

```
barplot(totales_sexo,
        col = c("#FF69B4", "#1E90FF"),
        main = "Distribución de estudiantes por sexo",
        ylab = "Cantidad de estudiantes",
```

```
ylim = c(0, max(totales_sexo) * 1.2))
```

```
# Agregar etiquetas
```

```
text(x = c(0.7, 1.9),  
     y = totales_sexo,  
     label = paste0(porcentaje, "%"),  
     pos = 3,  
     cex = 1.2,  
     col = "black")
```



***# Se observa que la participación masculina es significativamente mayor que la femenina,
representando aproximadamente el 78% del total de estudiantes, mientras que las mujeres***


constituyen cerca del 22%, evidenciando una diferencia notable en la matrícula por sexo.

4.4 Evolución en el tiempo

Se analiza la evolución de la matrícula a lo largo del tiempo


```
totales_por_ano <- aggregate(Total ~ Ano, data = df_carreras, sum)
```

```
plot(totales_por_ano$Ano, totales_por_ano$Total,  
     type = "o",  
     col = "darkgreen",  
     main = "Evolución de estudiantes en el tiempo",  
     xlab = "Año",  
     ylab = "Total de estudiantes")
```



*# Se observa una tendencia creciente en la cantidad de estudiantes a lo largo del tiempo,
especialmente en los años más recientes.*

4.5 Evolución por Sexo

Agrupar por año y sexo

```
fem <- aggregate(Femenino ~ Ano, data = df_carreras, sum)
```


```
masc <- aggregate(Masculino ~ Ano, data = df_carreras, sum)
```

Gráfico

```
plot(fem$Año, fem$Femenino,  
     type = "o",  
     col = "pink",  
     ylim = c(0, max(masc$Masculino)),  
     main = "Evolución de estudiantes por sexo",  
     xlab = "Año",  
     ylab = "Cantidad")
```

```
lines(masc$Año, masc$Masculino,  
      type = "o",  
      col = "blue")
```

```
legend("topleft",  
      legend = c("Femenino", "Masculino"),  
      col = c("pink", "blue"),  
      lty = 1)
```



4.6 Análisis por carrera

Total por carrera

```
total_carrera <- aggregate(Total ~ Carrera, data = df_carreras, sum)
```

```
# Ordenar de mayor a menor
```


```
total_carrera <- total_carrera[order(-total_carrera$Total), ]
```

```
# top 10
```

```
top10 <- head(total_carrera, 10)
```

```
par(mar = c(15, 8, 4, 2))
```

```
barplot(top10$Total,  
        names.arg = top10$Carrera,  
        las = 2,  
        col = "darkorange",  
        main = "Top 10 carreras con mayor cantidad de estudiantes",  
        ylim = c(0, max(top10$Total) * 1.2),  
        cex.names = 0.8)
```



*# Se identifican las carreras con mayor cantidad de estudiantes,
destacándose aquellas con mayor demanda dentro del dataset.*

5- Conclusión

**# El análisis exploratorio permitió identificar que la mayoría de las carreras presentan
una baja cantidad de estudiantes, mientras que unas pocas concentran valores
significativamente más altos,**

evidenciando una distribución desigual en la matrícula.

**# Asimismo, se observó que la participación masculina es considerablemente mayor que
la femenina.**

**# Este comportamiento puede estar relacionado con la naturaleza de las carreras
analizadas,**

**# principalmente orientadas al área de informática y tecnología, las cuales
históricamente**

han sido cursadas en mayor proporción por hombres.

**# A lo largo del tiempo, se evidenció una tendencia creciente en la cantidad total de
estudiantes,**

**# especialmente en los años más recientes, lo que indica un aumento sostenido en la
matrícula.**

**# Finalmente, el análisis de relaciones entre variables confirmó una dependencia directa
entre**

**# la cantidad de estudiantes por sexo y el total, así como la concentración de la demanda
en ciertas carreras,**

destacándose aquellas vinculadas al ámbito tecnológico.